



Benchmarking de Redes Neurais de Grafos Espaço-Temporais para Previsão de Séries Temporais em Domínios de Grafos Heterogêneos

*Lightning Talk - ENREDANDO 2026 - 28/07/2026
Universidade Federal de Viçosa (UFV), MG, Brasil.*

Gabriel F. Costa¹, Vander L. S. Freitas¹
¹ Universidade Federal de Ouro Preto (UFOP)

CEP: 35400-000 - Ouro Preto - MG - Brasil

PPGCC - Programa de Pós-Graduação em Ciência da Computação

Motivação

Estrutura relacional

Vértices

$$\mathcal{V} = \{ \text{blue circle}, \text{green circle}, \text{orange circle}, \text{purple circle}, \text{red circle} \}$$


Arestas

$$\mathcal{A}(t) =$$



Matriz de características


$$\mathbf{X}(t) =$$



$$N \times F$$

Informação Temporal + Informação Relacional

$$\mathcal{G}(t) = (\mathcal{V}(t), \mathcal{E}(t), \mathbf{X}(t))$$




$$\mathcal{G}_{t_1:t_2} = \{\mathcal{G}(t_1), \dots, \mathcal{G}(t), \dots, \mathcal{G}(t_2)\}$$

Séries Temporais dos Nós


contexto

horizonte



Vetor Histórico de Cada Nó em um Instante

v_i



$$\mathbf{x}_i(t) = [x_i(t-L+1), \dots, x_i(t)]^T, \in \mathbb{R}^L$$

$$F = L, \quad \mathbf{X}(t) \in \mathbb{R}^{N \times F}$$

Gap da Literatura

LITERATURA ATUAL



PRÉ-PROCESSAMENTO




- Normalizações diferentes
- Seleção de features distinta
- Construção de grafos variada

DIVISÕES TEMPORAIS



- Proporções de treino/val/teste
- Janelas de tempo variadas
- Horizontes de previsão distintos

ARQUITETURAS E HIPERPARÂMETROS




- Capacidades diferentes
- Configurações não padronizadas
- Busca de hiperparâmetros variada

TREINAMENTO



- Otimizadores distintos
- Taxas de aprendizado variadas
- Estratégias de regularização diferentes

MÉTRICAS E AVALIAÇÃO



- Métricas diferentes
- Relatos incompletos
- Testes estatísticos inconsistentes

ANÁLISES POUCO EXPLORADAS



- Poucos estudos relacionam espectro do grafo e sinais com desempenho
- Predominam análises pontuais e não descritivas



IMPACTO:

Diferenças de desempenho podem decorrer do protocolo experimental, e não apenas da arquitetura.



PERGUNTA CENTRAL:

Como diferentes famílias de STGNNs se comportam sob o mesmo protocolo experimental e regimes distintos, em grafos de diferentes domínios?

NOSSA PROPOSTA: BENCHMARK UNIFICADO E REPRODUZÍVEL + ANÁLISES ABRANGENTES

4 DATASETS HETEROGÊNEOS



Domínios com propriedades de grafos e padrões espaço-temporais distintos

21 ARQUITETURAS STGNN



- Convolucionais
- Recorrentes
- Baseadas em Atenção

PIPELINE UNIFICADO




- Mesmo pré-processamento
- Mesma construção de grafo
- Mesma representação de entrada

TREINAMENTO PADRONIZADO




- Mesmo otimizador
- Mesmos hiperparâmetros
- Múltiplas sementes

AVALIAÇÃO COMPARÁVEL




- RMSE como métrica principal
- Testes estatísticos
- CD Diagrams

ANÁLISE ESPECTRAL DO GRAFO E SINAIS




- Espectro do Laplaciano
- Distribuição de energia espectral dos sinais
- Associação espectro-desempenho

ANÁLISE DESCRITIVA



- Agrupamento de modelos
- Perfis de desempenho
- Interpretação de comportamentos

ABLAÇÃO DA PROJEÇÃO DE ENTRADA



- Impacto da projeção na performance
- Custo computacional




A escolha da arquitetura deve ser orientada pelo domínio do problema, considerando conjuntamente as características espectrais do grafo, o regime de previsão, o operador espacial e o módulo temporal.


Resultados Preliminares: Diagrama DC - Curto a Médio Prazo

Critical Difference Diagrams


a) Hungary Chickenpox Dataset




b) Wikipedia Mathematics Dataset



c) England COVID-19 Dataset



d) Montevideo Bus Dataset



Arquiteturas estatisticamente equivalentes ($\alpha=0,05$).

Ranking da melhor para a pior arquitetura


Famílias

- Atencionais
- Convolucionais
- Recorrentes


Resultados Preliminares: Diagrama DC - Longo Prazo

Critical Difference Diagrams (Long)


a) Hungary Chickenpox Dataset




b) Wikipedia Mathematics Dataset



c) England COVID-19 Dataset




d) Montevideo Bus Dataset



Arquiteturas estatisticamente equivalentes ($\alpha=0,05$).



Ranking da melhor para a pior arquitetura

Famílias





Resultados: Ablação da Projeção de Entrada

ΔRMSE by Dataset (No Input Projection vs Input Projection)



$$\Delta\text{RMSE} = \text{RMSE}_{\text{noIP}} - \text{RMSE}_{\text{IP}},$$



Famílias



Contribuições



ANÁLISE ESPECTRAL

- Relacionamos o espectro do grafo com o desempenho das STGNNs.
- Identificamos o alinhamento espectral esperado dos sinais.
- Explicamos por que diferentes arquiteturas se comportam melhor em diferentes grafos e regimes.



DESEMPENHO E CUSTO

- Avaliamos 21 arquiteturas STGNNs em 4 datasets sob o mesmo protocolo.
- Medimos o erro de previsão (RMSE) e o custo computacional.
- Evidenciamos o trade-off entre precisão e custo.



BENCHMARK REPRODUZÍVEL

- Disponibilizamos código-fonte, configurações e hiperparâmetros.
- Incluímos datasets e divisões usadas nos experimentos.
- Garantimos transparência e reprodutibilidade.

QR Code
Paper & Code



CONCLUSÕES



NÃO HÁ UM VENCEDOR UNIVERSAL

Nenhuma arquitetura se destaca em todos os domínios e horizontes.



DESEMPENHO DEPENDE DAS CARACTERÍSTICAS

Características espectrais do grafo e do sinal e o regime de previsão influenciam o desempenho.



BENCHMARK REPRODUZÍVEL

Fornecemos um benchmark completo para impulsionar pesquisas futuras.



A escolha da arquitetura deve ser orientada pelo domínio do problema, considerando conjuntamente as características espectrais do grafo, o regime de previsão, o operador espacial e o módulo temporal.

Agradeço pela atenção!

Referências:

1. Jin, M., Koh, H. Y., et al. Survey on graph neural networks for time series: forecasting, classification, imputation, and anomaly detection. *IEEE Trans. Pattern Anal. Mach. Intell.*, 2024.
2. Li, Y., Yu, R., Shahabi, C., Liu, Y. Diffusion Convolutional Recurrent Neural Network for traffic forecasting. *ICLR*, 2018.
3. Vaswani, A., et al. Attention is All You Need. *NeurIPS*, 2017.
4. Wu, Z., Pan, S., Chen, F., Long, G., Zhang, C., Yu, P. S. Graph WaveNet for deep spatial-temporal graph modeling. *IJCAI*, 2019.
5. Yu, B., Yin, H., Zhu, Z. Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting. *IJCAI*, 2018.
6. Rozemberczki, B., Allen, C., Sarkar, R. Chickenpox Cases in Hungary: A Spatio-Temporal Graph Benchmark. *arXiv:2105.07162*, 2021.
7. Zhang, K., Zheng, X., et al. A Survey on Deep Learning for Time Series Forecasting: Models, Methods, and Applications. *ACM Comput. Surv.*, 2023.
8. Joshi, S., et al. Transformers are Graph Neural Networks. 2025.